LAPORAN PRAKTIKUM

ANALISIS SENTIMEN KOMENTAR MAHASISWA MENGGUNAKAN TF-IDF DAN NAIVE BAYES

Dibuat Untuk Memenuhi Tugas Laporan Praktikum Mata Kuliah Natural Language Processing

Dosen Pengampu: Dr. Risky Aswi Ramadhani, S.Kom, M.Kom



Oleh:

Nama: Muhammad Asla Labiib Badaly

NPM: 2213020065

Kelas: 4A

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNIK & ILMU KOMPUTER

UNIVERSITAS NUSANTARA PGRI KEDIRI

2026

BAB I
PENDAHULUAN

A. Latar Belakang

Perkembangan teknologi informasi memungkinkan lembaga pendidikan untuk mengumpulkan berbagai masukan dari mahasiswa, baik yang bersifat kritis maupun tidak penting. Komentar mahasiswa dapat digunakan sebagai alat evaluasi untuk meningkatkan kualitas layanan akademik dan fasilitas kampus.

Namun, pengolahan komentar secara manual membutuhkan banyak waktu dan tenaga. Oleh karena itu, sistem otomatis yang dapat mengklasifikasikan komentar mahasiswa ke dalam kategori tertentu, seperti saran dan bukan saran, diperlukan.

Dalam praktik ini, metode *Text Mining* menggunakan pendekatan TF-IDF (*Term Frequency–Inverse Document Frequency*) dan algoritma *Naive Bayes* digunakan untuk mengklasifikasikan komentar mahasiswa secara otomatis.

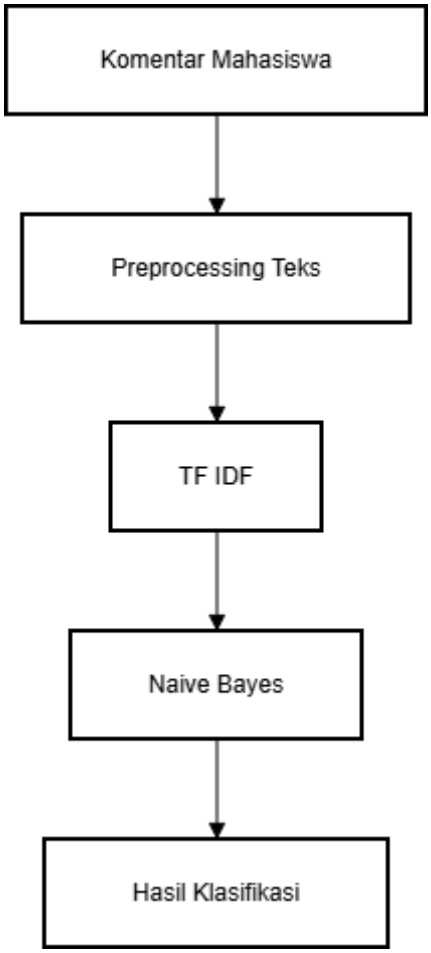
B. Rumusan Masalah

1. Bagaimana proses pengolahan teks komentar mahasiswa agar dapat dianalisis oleh sistem?
2. Bagaimana penerapan metode TF-IDF dalam merepresentasikan data teks?
3. Bagaimana performa algoritma Naive Bayes dalam mengklasifikasikan komentar mahasiswa?
4. Bagaimana cara mengetahui keakuratan sistem dalam menganalisis data?
5. Bagaimana pengaruh penambahan data otomatis (pseudo-labeling) terhadap hasil klasifikasi?

C. Solusi

1. Melakukan preprocessing teks meliputi case folding, tokenizing, stopword removal, dan stemming.
2. Mengubah teks menjadi fitur numerik menggunakan metode TF-IDF.
3. Melatih model klasifikasi menggunakan algoritma Naive Bayes.
4. Melakukan evaluasi model menggunakan akurasi dan confusion matrix.
5. Menambahkan data baru secara otomatis menggunakan metode pseudo-labeling berdasarkan tingkat kepercayaan model.

D. Gambar dan Code



Gambar 1. Flowchart Program

Source Code:

```
import pandas as pd
import re

from Sastrawi.Stemmer.StemmerFactory import StemmerFactory
from Sastrawi.StopWordRemover.StopWordRemoverFactory import
StopWordRemoverFactory

from sklearn.model_selection import train_test_split
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.naive_bayes import MultinomialNB
from sklearn.metrics import accuracy_score, classification_report,
confusion_matrix

data = pd.read_csv("dataset_komentar_mahasiswa_variasi.csv")

print("Jumlah data awal:", len(data))
print("Distribusi label awal:")
print(data["label"].value_counts())
print("-" * 50)
```

```
factory = StemmerFactory()
stemmer = factory.create_stemmer()

stop_factory = StopWordRemoverFactory()
stopwords = set(stop_factory.get_stop_words())

def preprocess(text):
    text = text.lower()
    text = re.sub(r'[^a-z\s]', '', text)
    tokens = text.split()
    tokens = [t for t in tokens if t not in stopwords]
    text = " ".join(tokens)
    text = stemmer.stem(text)
    return text

data["komentar_clean"] = data["komentar"].apply(preprocess)

def train_evaluate(df):
    tfidf = TfidfVectorizer()
    X = tfidf.fit_transform(df["komentar_clean"])
    y = df["label"]

    X_train, X_test, y_train, y_test = train_test_split(
        X, y,
        test_size=0.2,
        random_state=42,
        stratify=y
    )

    model = MultinomialNB()
    model.fit(X_train, y_train)

    y_pred = model.predict(X_test)

    print("Akurasi:", accuracy_score(y_test, y_pred))
    print("\nClassification Report:")
    print(classification_report(y_test, y_pred))

    cm = confusion_matrix(y_test, y_pred)
    cm_df = pd.DataFrame(cm, index=model.classes_,
columns=model.classes_)
    print("\nConfusion Matrix:")
    print(cm_df)

    return model, tfidf

print("=== HASIL SEBELUM DATA OTOMATIS ===")
model, tfidf = train_evaluate(data)
```

```
print("-" * 50)

CONFIDENCE_THRESHOLD = 0.75

while True:
    komentar_user = input(
        "\nMasukkan komentar mahasiswa "
        "(ketik 'exit' untuk selesai input): "
    )

    if komentar_user.lower() == "exit":
        break

    komentar_clean = preprocess(komentar_user)
    komentar_tfidf = tfidf.transform([komentar_clean])

    prob = model.predict_proba(komentar_tfidf)[0]
    pred_label = model.classes_[prob.argmax()]
    confidence = prob.max()

    print(f"Hasil Prediksi: {pred_label}")
    print(f"Confidence     : {confidence:.2f}")

    if confidence >= CONFIDENCE_THRESHOLD:
        data.loc[len(data)] = [
            komentar_user,
            pred_label,
            komentar_clean
        ]
        print("✔ Data otomatis ditambahkan ke dataset")
    else:
        print("❌ Confidence rendah → data tidak disimpan")

data.to_csv("dataset_komentar_mahasiswa_updated.csv", index=False)
print("\nDataset baru disimpan!")
print("Jumlah data sekarang:", len(data))
print("-" * 50)

print("=== HASIL SETELAH DATA OTOMATIS ===")
model, tfidf = train_evaluate(data)
```

Hasil:

```
PS C:\Users\ASUS\OneDrive\Documents\NLP> & "C:/Program Files/Python312/python.exe" c:/Users/ASUS/OneD
e\Documents\NLP> & "C:/Program Files/Python312/python.exe" c:/Users/ASUS/OneDrive/Documents/NLP/senti
Jumlah data awal: 45
Distribusi label awal:
label
Saran          25
Bukan Saran    20
Name: count, dtype: int64
--------------------------------------------------
=== HASIL SEBELUM DATA OTOMATIS ===
Akurasi: 0.7777777777777778

Classification Report:
              precision    recall  f1-score   support

 Bukan Saran       1.00      0.50      0.67         4
       Saran       0.71      1.00      0.83         5

    accuracy                           0.78         9
   macro avg       0.86      0.75      0.75         9
weighted avg       0.84      0.78      0.76         9


Confusion Matrix:
            Bukan Saran  Saran
Bukan Saran            2      2
Saran                  0      5
--------------------------------------------------

Masukkan komentar mahasiswa (ketik 'exit' untuk selesai input): tambahkan hospot area kampus 2
Hasil Prediksi: Saran
Confidence     : 0.68
❌Confidence rendah → data tidak disimpan

Masukkan komentar mahasiswa (ketik 'exit' untuk selesai input): hospot area sebaiknya ditambah
Hasil Prediksi: Saran
Confidence     : 0.80
✅Data otomatis ditambahkan ke dataset

Masukkan komentar mahasiswa (ketik 'exit' untuk selesai input): exit
```

```
Masukkan komentar mahasiswa (ketik 'exit' untuk selesai input): exit

Dataset baru disimpan!
Jumlah data sekarang: 46
--------------------------------------------------
=== HASIL SETELAH DATA OTOMATIS ===
Akurasi: 0.8

Classification Report:
              precision    recall  f1-score   support

 Bukan Saran       1.00      0.50      0.67         4
       Saran       0.75      1.00      0.86         6

    accuracy                           0.80        10
   macro avg       0.88      0.75      0.76        10
weighted avg       0.85      0.80      0.78        10


Confusion Matrix:
            Bukan Saran  Saran
Bukan Saran            2      2
Saran                  0      6
PS C:\Users\ASUS\OneDrive\Documents\NLP>
```